课程笔记

Stanford CS231N 深度学习计算机视觉
第一讲：课程介绍

五道口纳什 & Codex

2026 年 3 月 24 日

视频作者/频道：Stanford Online
发布日期：2025 年 9 月 2 日
视频时长：1:02:52
视频链接：https://www.youtube.com/watch?v=2fq9wYslV0A

目录

1 课程概述 **3**

1.1 AI 的学科版图 3

1.2 本章小结 4

2 视觉的起源：5.4 亿年的进化史 **4**

2.1 寒武纪大爆发与视觉的诞生 4

2.2 人类文明对视觉的探索：从针孔到相机 4

2.3 本章小结 5

3 生物视觉与神经科学：给计算机视觉的启示 **5**

3.1 Hubel & Wiesel 的猫实验（1959） 5

3.2 计算机视觉的诞生（1960s） 6

3.3 David Marr 的视觉计算理论（1970s） 7

3.4 本章小结 8

4 计算机视觉的历史演进 **8**

4.1 早期计算机视觉（1970s–1980s） 8

4.2 认知神经科学的指引：物体识别的北极星 9

4.3 数据时代的曙光：从小数据集到 ImageNet 10

4.4 本章小结 11

5 数据革命：ImageNet 与深度学习的诞生 **11**

5.1 ImageNet 的创建 11

5.2 2012 年：AlexNet 与深度学习的历史性时刻 11

5.3 神经网络与反向传播的发展历程 12

5.4 本章小结 15

6 深度学习时代的爆发 **15**

6.1 2012 年之后的视觉任务爆炸 15

6.2 三大收敛力量 16

6.3 本章小结 17

7 课程内容：四大主题模块 **17**

7.1 模块一：深度学习基础 18

7.2 模块二：感知与理解视觉世界 19

7.3 模块三：大规模分布式训练 20

7.4 模块四：生成式与交互式视觉智能 20

7.5 本章小结 21

8 人本 AI 与社会影响 **21**

8.1 AI 的”好”与”坏” 21

8.2 领域里程碑：图灵奖与诺贝尔奖 22

8.3 下一讲预告 23

8.4 本章小结 23

9 总结与延伸 **23**

9.1 讲师的结语与综合 23

9.2 核心知识图谱 24

9.3 我的综合与延伸 24

9.4 拓展阅读 25

1 课程概述

CS231N 是 Stanford 大学开设的旗舰课程——**面向计算机视觉的深度学习**。本课由 **Fei-Fei Li 教授**（计算机科学系）、**Ehsan Adeli 教授**以及博士生 **Zane** 联合讲授，2025 年春季学期开课。

本讲内容分为两个部分：

1. **Fei-Fei Li**：计算机视觉与深度学习的历史回顾
2. **Ehsan Adeli**：课程结构、主题与学习目标概述

课程核心定位

本课程聚焦于**计算机视觉**与**深度学习**的核心交叉地带。它既不覆盖计算机视觉的全部，也不覆盖机器学习/深度学习的全部，而是专注于两者最重要的交集。

1.1 AI 的学科版图

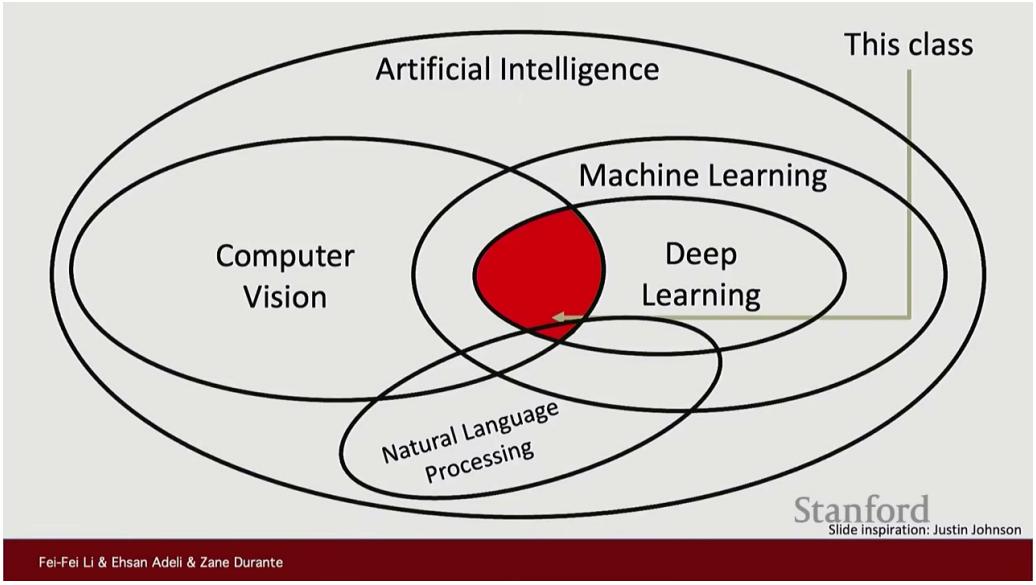

图 1: AI 学科版图：课程聚焦计算机视觉与深度学习的交叉（红色区域）[1]

如图所示，AI 是一个大的领域，计算机视觉是其中不可分割的一部分。在 AI 的数学工具中，**机器学习（统计机器学习）**是最核心的工具之一。而在过去十余年，机器学习内部出现了一场革命——**深度学习**：

- **深度学习**：以**神经网络**为核心的一类算法技术体系
- 神经网络是深度学习的基础构建模块

计算机视觉与众多领域高度交叉，包括：自然语言处理、语音识别、机器人学，以及数学、神经科学、心理学、物理、生物等基础学科，乃至医疗、法律、教育、商业等应用领域。

[1] 视频画面时间区间：00:02:28。

AI 作为跨学科领域

Fei-Fei Li 强调，AI 已成为一个真正的跨学科领域。她希望学生不论来自哪个专业，都能将课程所学与自己的领域相结合。这种跨学科视角贯穿整门课程。

1.2 本章小结

本课程在 AI 的宏观版图中定位于计算机视觉与深度学习的核心交叉。课程目标不仅是技术教育，更强调跨学科应用。

2 视觉的起源：5.4 亿年的进化史

2.1 寒武纪大爆发与视觉的诞生

视觉的历史不始于人类，而始于大约 **5.4 亿年前的寒武纪大爆发（Cambrian Explosion）**。

古生物学研究表明，在进化史上约 1000 万年的极短时期内，动物物种发生了爆炸式增长。在此之前，地球生命相对单调，主要在水中漂浮，以新陈代谢维持被动生存。

视觉诞生的关键：三叶虫（trilobite）是已知最早拥有光感细胞的动物。这些”眼睛”并非复杂的晶状体和视网膜，而只是最简单的**针孔结构（pinhole）**，能够收集光线。

传感器改变了生命的本质

没有传感器，生命只是新陈代谢——极度被动。一旦有了传感器（尤其是视觉），生命体就能主动感知、改变并生存于环境中：猎食，也被猎食。进化压力由此驱动智能快速涌现。

5.4 亿年视觉进化 = 智能进化的核心主线。视觉作为动物最主要的感官之一，驱动了神经系统和智能的发展。今天地球上几乎所有已知动物都使用视觉作为主要感官之一。

人类尤其是视觉性动物——**超过一半的皮层细胞参与视觉处理**，我们拥有极为复杂的视觉系统。

2.2 人类文明对视觉的探索：从针孔到相机

人类不仅能看，还渴望构建会看的机器：

- **古希腊、古中国**：哲学家已记录关于针孔成像的思考
- **莱昂纳多 · 达 · 芬奇**：研究暗箱（camera obscura），探索如何将三维物体投影为二维图像
- **现代相机**：已无处不在，但相机只是工具，就像眼睛只是器官——真正的挑战在于视觉**智能**

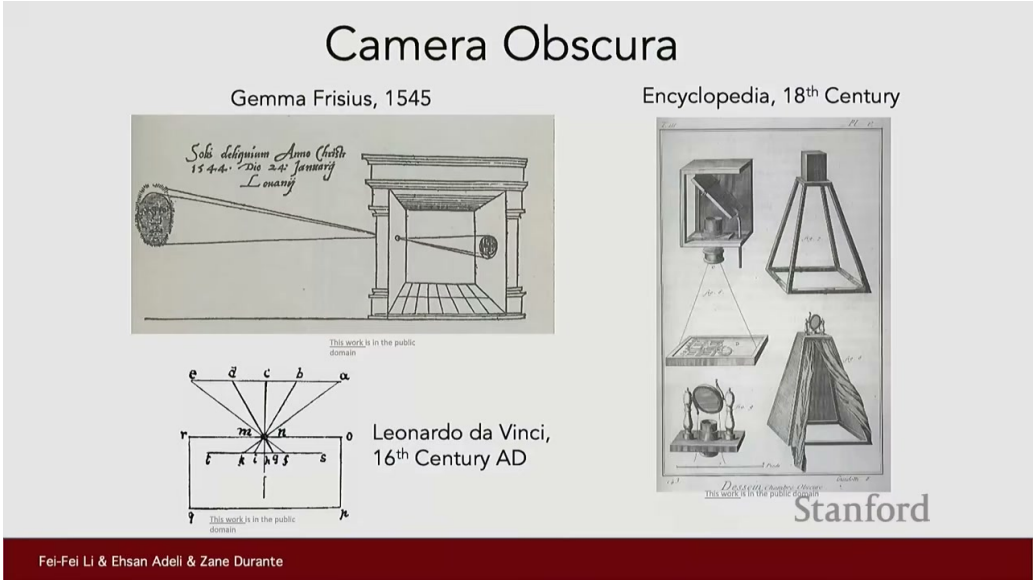

图 2: Camera Obscura：从古代针孔成像到达芬奇的暗箱研究[2]

眼睛 ≠ 视觉

眼睛（或相机）只是感光装置。真正的视觉需要理解——这正是这门课的核心问题。

2.3 本章小结

视觉是智能的基石。从 5.4 亿年前的寒武纪大爆发到现代相机，视觉传感器的出现始终是驱动智能进化与技术革命的关键力量。

3 生物视觉与神经科学：给计算机视觉的启示

3.1 Hubel & Wiesel 的猫实验（1959）

1959 年，神经科学家 **David Hubel** 和 **Torsten Wiesel** 进行了一项奠基性实验：他们将电极植入麻醉猫的初级视觉皮层，研究神经元的感受野（receptive field）。

[2] 视频画面时间区间：00:06:23。

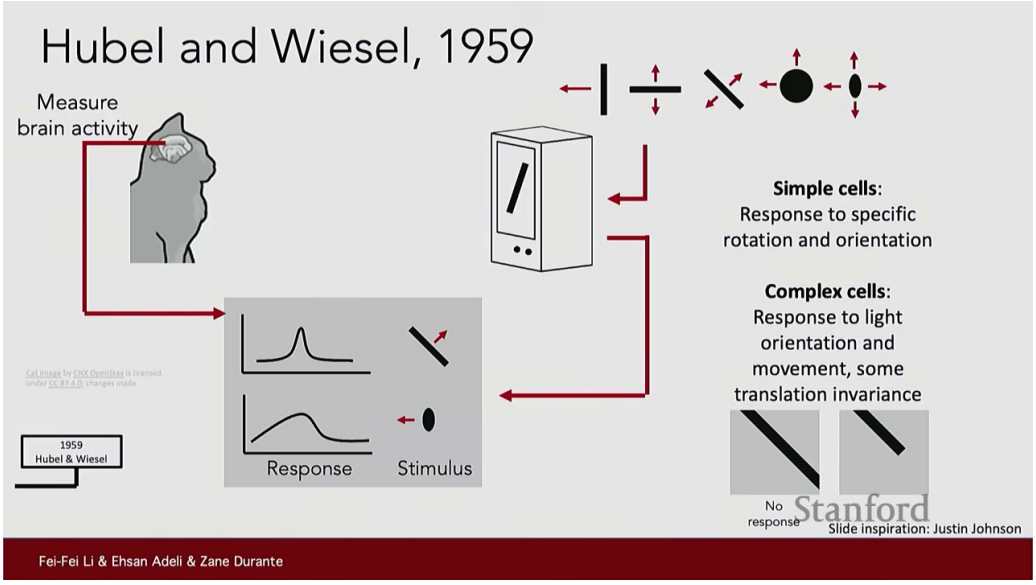

图 3: Hubel & Wiesel（1959）：猫视觉皮层实验——简单细胞与复杂细胞的发现[3]

两大核心发现：

1. **局部感受野**：每个视觉皮层神经元只响应视野中的一小块区域，并在该区域内专门识别简单模式（如特定方向的边缘）。初级视觉皮层（位于枕叶后部）的神经元主要响应**有方向的边缘（oriented edges）**或运动的方向边缘。

2. **层次化视觉处理**：视觉通路是分层的。越往高层，神经元的感受野越复杂：边缘 → 角点 → 物体部件 → 物体。

层次化处理：神经网络的生物原型

Hubel & Wiesel 的发现——局部感受野 + 层次化处理——直接启发了后来的卷积神经网络（CNN）设计。简单感受野 → 复杂感受野的层级结构，正是现代深度学习架构的生物学依据。

Hubel & Wiesel 因这项工作于约 20 年后（1981 年）荣获**诺贝尔生理学或医学奖**。

3.2 计算机视觉的诞生（1960s）

Larry Roberts（1963）：被认为是计算机视觉史上第一篇 PhD 论文，研究如何从图像中理解积木形状的表面、角点和特征——这是一个对人类而言极为直觉化，但在计算机上极具挑战性的任务。

[3]视频画面时间区间：00:07:39–00:08:20。

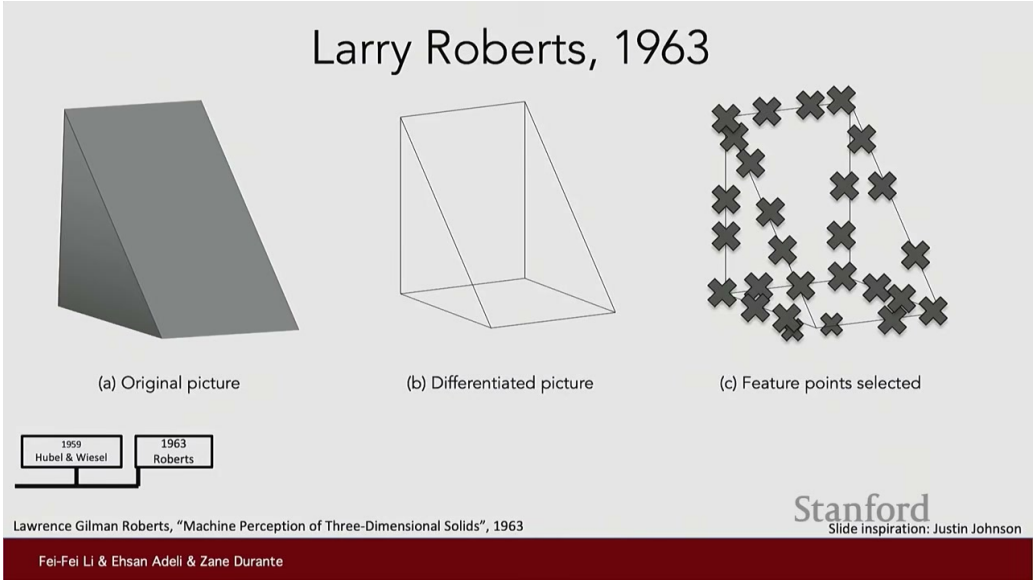

图 4: Larry Roberts（1963）：计算机视觉的第一篇博士论文——三维实体的机器感知[4]

MIT 夏季项目（1966）：一位 MIT 教授将"解决计算机视觉"列为一个暑期项目目标，聘用了几名优秀本科生。这体现了早期 AI 研究者的典型过度乐观——视觉并没有在那个夏天被解决，但这个领域由此正式诞生。

历史反复警示：AI 进展总被高估

从 1966 年的 MIT 夏季项目到此后每一次 AI 寒冬，历史一再证明：我们总是高估短期能做到的，低估长期的积累效应。

今天，计算机视觉的主要年度会议（如 CVPR）每年吸引超过 10,000 人参加。

3.3 David Marr 的视觉计算理论（1970s）

David Marr（可惜英年早逝）在 1970s 提出了系统性的视觉计算理论，将图像处理分为三个层次：

1. **Primal Sketch（原始草图）**：提取边缘，类似视觉皮层的初级处理
2. **2.5D Sketch**：区分前景/背景，获取深度和表面方向的粗略表示
3. **完整 3D 表示**：视觉的终极目标——恢复完整的三维世界

[4] 视频画面时间区间：00:11:01。

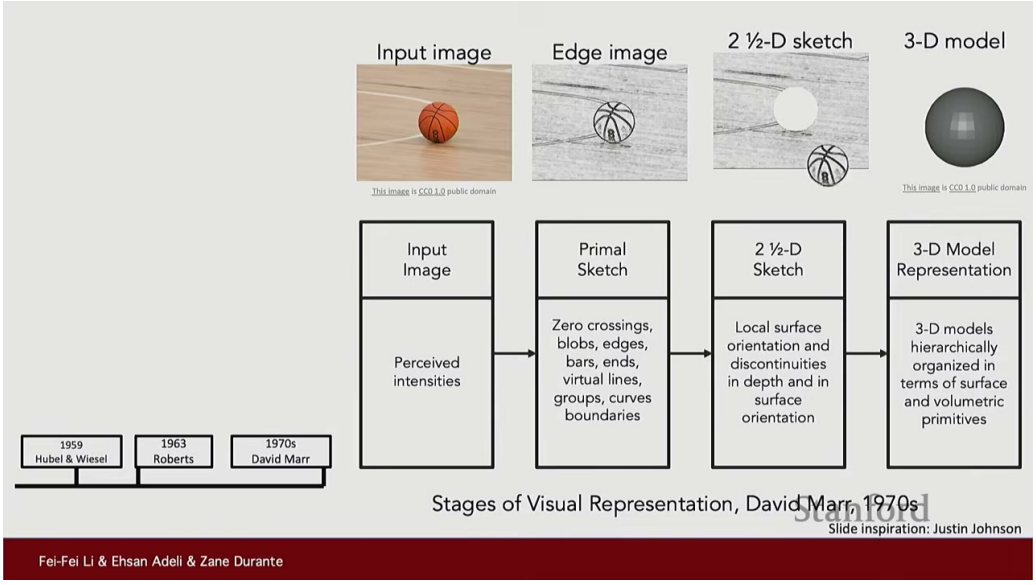

图 5: David Marr 的视觉计算理论（1970s）：从原始草图到 3D 模型的分层表示[5]

视觉的根本难题：从 2D 恢复 3D

从三叶虫到人类，视觉的物理本质始终是：三维世界的光子投影到二维表面（视网膜/感光细胞）。从 2D 图像重建完整的 3D 信息在数学上是一个**不适定问题（ill-posed problem）**——信息是欠定的。自然界的解法：发展出双眼（stereo vision），通过视差三角化来恢复深度。

语言 vs 视觉的根本差异

语言是人类”生成”的——它是 1D、序列化的、不存在于自然界中。这正是为什么 LLM 如此强大，因为可以用序列模型建模语言。但视觉不同——物理世界是真实存在的，服从物理定律和材质约束，是 2D 投影的 3D 现实。两者的本质差异对算法设计有深远影响。

3.4 本章小结

神经科学（尤其是 Hubel & Wiesel）揭示了视觉的层次化局部处理原则，直接启发了卷积神经网络。计算机视觉诞生于 1960s，David Marr 给出了系统性的计算框架，核心难题是从 2D 图像恢复 3D 世界。

4 计算机视觉的历史演进

4.1 早期计算机视觉（1970s–1980s）

1970s 物体识别的早期尝试：

- **广义柱体（Generalized Cylinders）**（Stanford，Rodney Brooks & Tom Binford）：用圆柱体组合来表示物体形状
- **组合模型**（Palo Alto 研究者）：用部件组合表示人体和物体

[5] 视频画面时间区间：00:12:53。

- **边缘检测算法**（1980s）：随着数字照片的出现，从图像中提取边缘草图

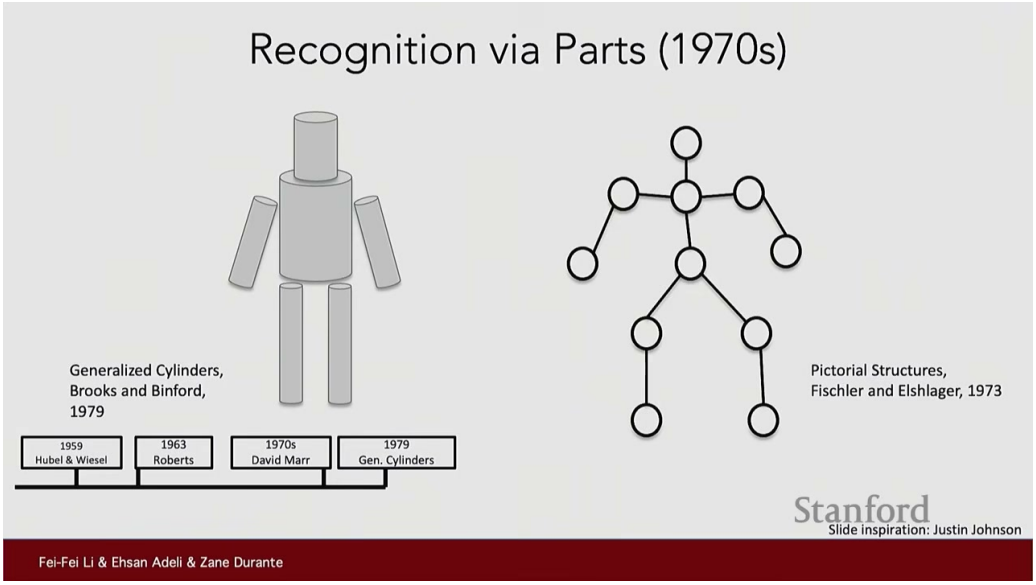

图 6: 1970s 物体识别：广义柱体（Brooks & Binford）与图形结构（Fischler & Elshlager）[6]

这些成果在今天看来似乎微不足道，但代表了那个年代在极有限算力和数据条件下的创新探索。

AI 寒冬（1980s）：由于计算机视觉、专家系统、机器人学等都未能兑现承诺，AI 研究热情和资助大幅萎缩，进入 AI 寒冬。

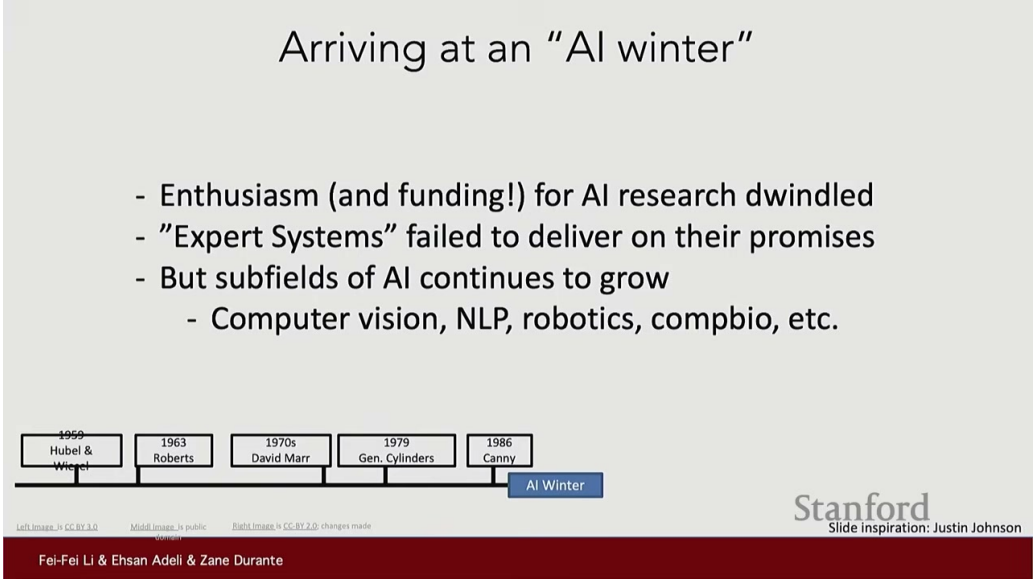

图 7: AI 寒冬：资金与热情衰退，但计算机视觉等子领域持续成长[7]

4.2 认知神经科学的指引：物体识别的北极星

即使在 AI 寒冬期间，认知神经科学持续揭示了重要方向：

[6] 视频画面时间区间：00:17:22。

[7] 视频画面时间区间：00:19:05。

Biederman 实验：检测自行车的正常图像 vs. 打乱后的图像——即使打乱前后，自行车的像素在视网膜上落点相同，但打乱后识别准确率大幅下降。这说明**上下文（整体场景）对物体识别至关重要**。

快速视觉识别实验（1970s）：以 10Hz 播放视频（每帧仅 100ms），人类仍能可靠检测出视频中出现的人。这说明人类视觉处理的**惊人速度**——神经元并不快（比晶体管慢很多个数量级），但仅需几次神经跳转（约 150ms）就能完成复杂分类。

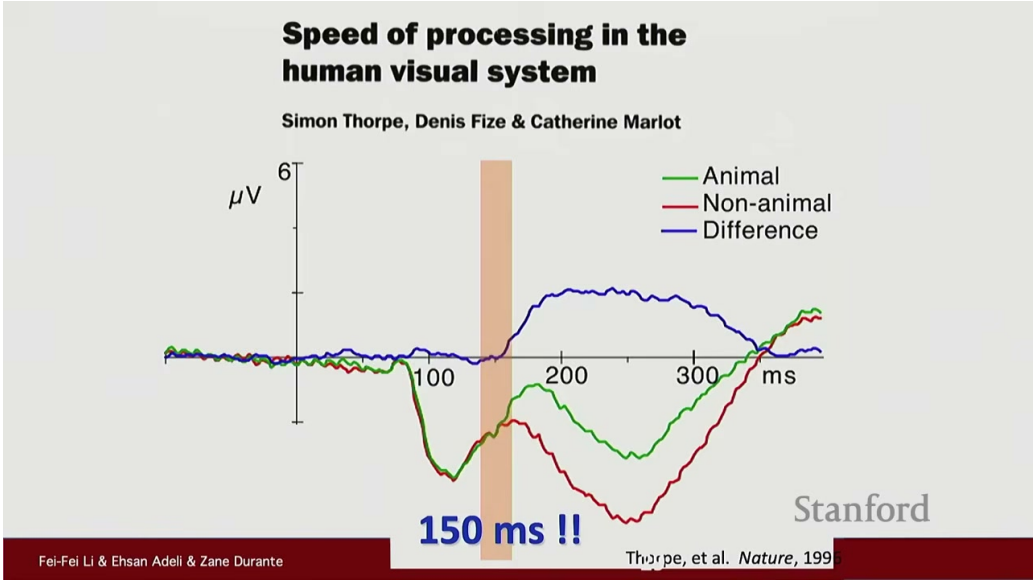

图 8: 人类视觉处理速度：150 毫秒完成动物/非动物分类（Thorpe EEG 实验）[8]

视觉处理的速度惊人

Simon Thorpe 的 EEG 实验证明：仅需 **150 毫秒**，人脑就能完成对自然场景中动物/非动物的分类，产生可测量的脑电差异信号。150ms 是极少数神经跳转，神经”湿件”比硅芯片慢很多，却能如此快速完成视觉分类，说明视觉处理是高度并行的。

3. 专门化脑区（MIT 1990s-21 世纪初）：人脑有专门识别人脸（fusiform face area）、地点（parahippocampal place area）、身体部件的专业化区域——这是长期进化形成的视觉专业化。

4.3 数据时代的曙光：从小数据集到 ImageNet

1990s–21 世纪初，计算机视觉的进展：

- **基于分组的识别（Recognition by Grouping）**：分离前景/背景物体
- **SIFT 特征**：手工设计的鲁棒图像特征，用于匹配
- **人脸检测**：Fei-Fei Li 进入博士第一年，这篇论文发表；5 年后被用于数码相机的自动对焦功能
- **PASCAL VOC 数据集**：数千 数万张图像，用于物体识别竞赛
- **Caltech 101**：另一个早期标准数据集

[8] 视频画面时间区间：00:21:53。

数据不足不只是”不方便”，而是一个根本性的数学问题：高容量算法需要大量数据才能学会泛化，否则会**过拟合**。

数据集的演进

Pascal VOC（约 2 万张图）→ Caltech 101（约 9000 张）→ ImageNet（150 万 + 张，1000 类）
每一步的数据规模跃升都对应着算法能力的重大进步。

4.4 本章小结

从 1970s 的积木世界到 1990s 的 SIFT 特征，计算机视觉历经数十年艰难探索。认知神经科学持续指引研究方向，核心问题始终是物体识别。数据的匮乏是这一时期的根本瓶颈。

5 数据革命：ImageNet 与深度学习的诞生

5.1 ImageNet 的创建

Fei-Fei Li 及其学生认识到：整个领域严重低估了**数据**的重要性——所有人都在关注架构，却忽视了数据。

ImageNet 的构建：

- 清洗约 10 亿张图像，保留约 **1500 万张**（可用于发布的部分）
- 跨越 **22,000 个类别**
- 22,000 个类别的规模参考了认知心理学文献——大约是人类在幼年时学会识别的类别数量
- 开源发布，同时创办 **ImageNet 大规模视觉识别挑战赛（ILSVRC）**

竞赛规则：从 ImageNet 中筛选出约 **100 万张图像、1000 个类别**，参赛算法在测试集上尽可能准确地识别这 1000 类物体。

5.2 2012 年：AlexNet 与深度学习的历史性时刻

ImageNet 竞赛结果：

- 首届（2010 年）：最优错误率接近 **30%**（人类约 3–5%）
- 2011 年：略有改善，但仍不令人振奋
- **2012 年：AlexNet**——Jeff Hinton 团队使用卷积神经网络参赛，错误率**几乎减半**（约 15%），震惊整个领域

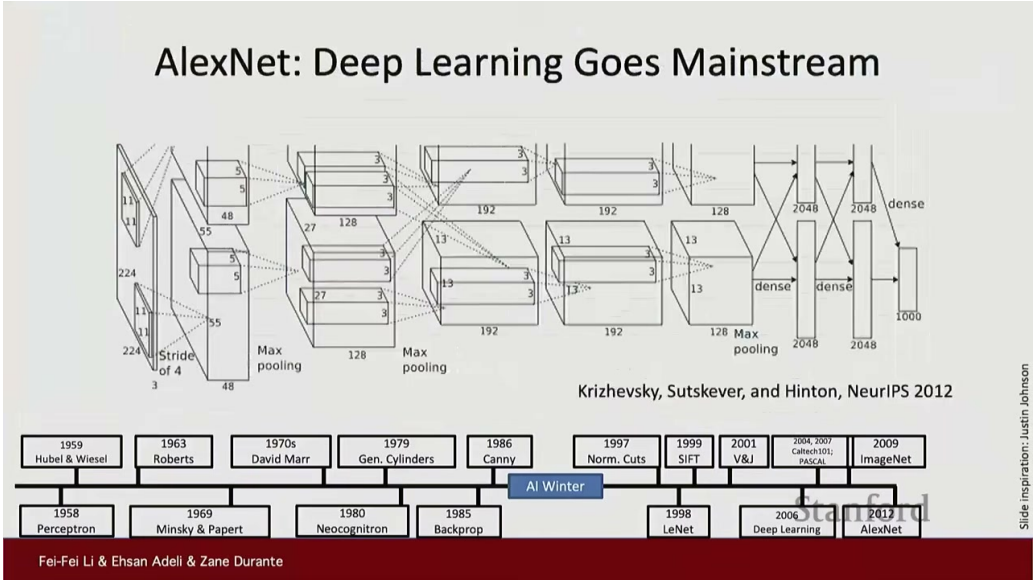

图 9: AlexNet（Krizhevsky, Sutskever & Hinton, 2012）：深度学习革命的历史性时刻[9]

AlexNet 并非凭空而来

AlexNet 与 32 年前 Fukushima 的 Neocognitron 结构并无本质区别。真正的突破来自两个要素的成熟：

1. **反向传播（Backpropagation）**：1986 年 Rumelhart & Hinton，一种原理性的、数学严谨的学习规则，无需手工调参
2. **大规模数据（ImageNet）**：高容量模型必须有足够数据才能泛化，数据是与架构同等重要的”一等公民”

这两者 + GPU 算力，共同触发了深度学习革命。

2012 年被广泛认为是现代 AI 复兴（或深度学习革命诞生）的历史性时刻。

5.3 神经网络与反向传播的发展历程

在追溯到 2012 年的革命之前，另一条并行的研究线索同样关键——神经网络的演进：

- **感知机（Perceptron）**（1950s-60s）：最早的人工神经元模型；Marvin Minsky 证明感知机无法学习 XOR，引发短暂挫折

[9] 视频画面时间区间：00:34:28。

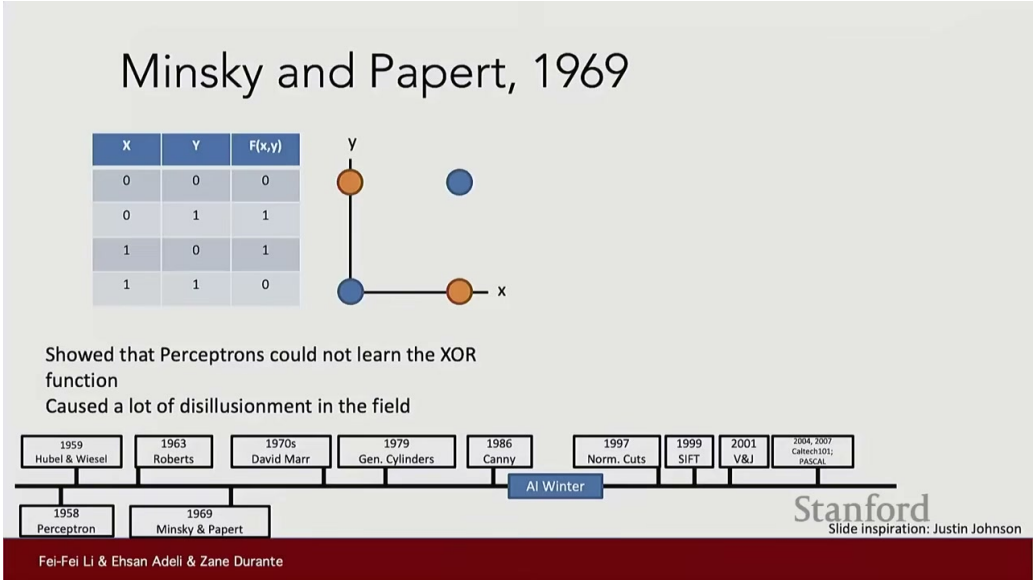

图 10: Minsky & Papert（1969）：证明感知机无法学习 XOR，引发领域失望[10]

- **Neocognitron（Fukushima, 1980）**：手工设计的约五六层神经网络，受视觉通路启发，早期层做卷积（简单感受野），后期层做池化（复杂感受野），可识别数字/字母。**但所有参数均为手工设定**，无法从数据中学习

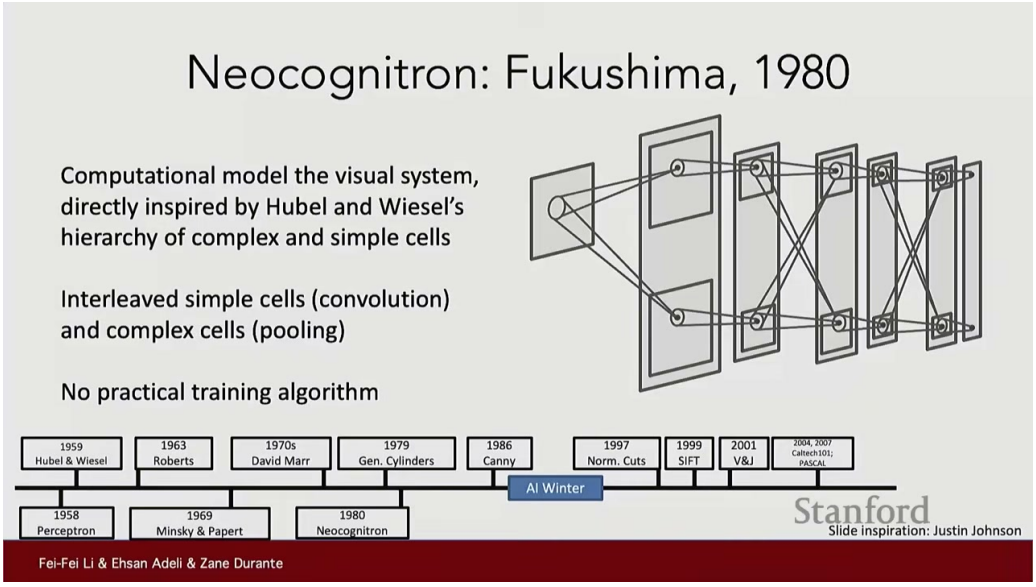

图 11: Neocognitron（Fukushima, 1980）：受视觉皮层启发的卷积/池化架构先驱[11]

- **反向传播（Backpropagation, 1986）**（Rumelhart, Hinton 等）：引入误差修正目标函数，通过链式法则将输出误差反向传播到整个网络，自动调整参数——这是理论上的重大突破

[10] 视频画面时间区间：00:26:46。
[11] 视频画面时间区间：00:28:15。

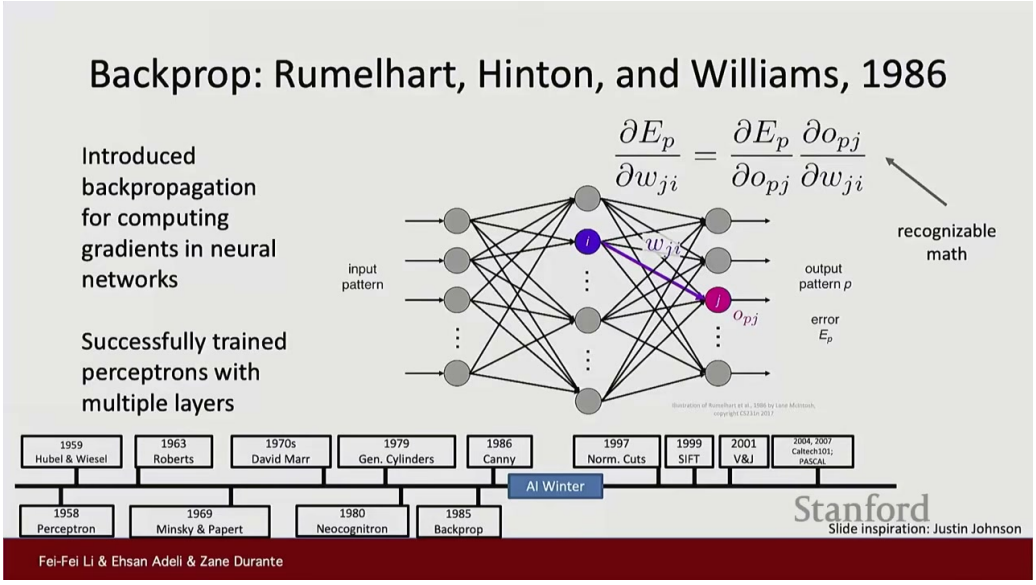

图 12: 反向传播（Rumelhart, Hinton & Williams, 1986）：神经网络的数学学习法则[12]

- **LeNet（Yann LeCun, 1990s）**：Bell Labs 开发的约七层卷积网络，可识别数字和字母，已被 US Postal Service 和银行实际部署用于手写数字识别

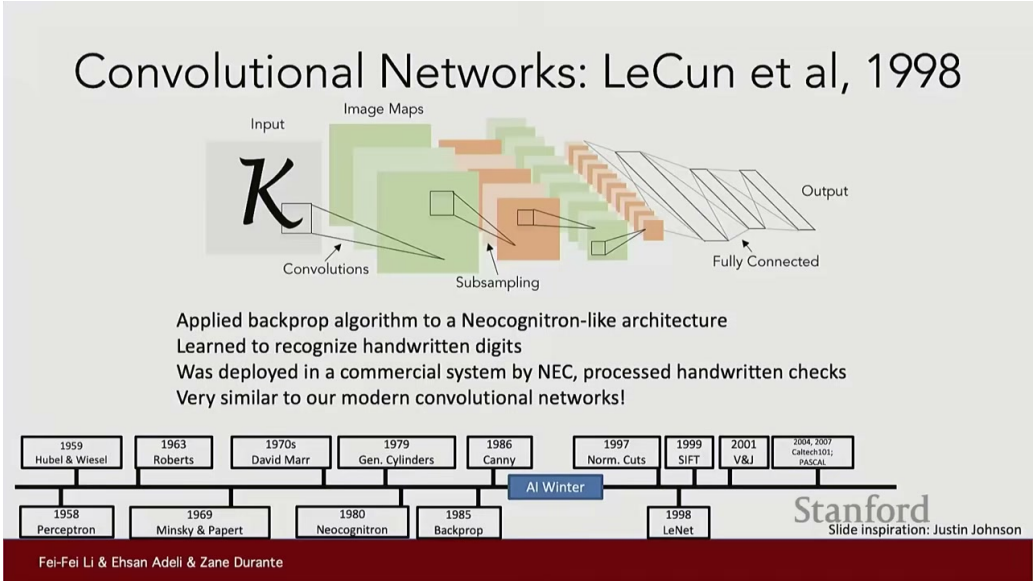

图 13: LeNet（LeCun, 1998）：第一个实用的卷积神经网络，已部署于邮政和银行[13]

- **停滞期（1990s-2000s）**：尽管有 LeNet 的成功，将神经网络推广到自然图像（猫、狗、椅子等）时依然失败——根本原因是数据不足

[12] 视频画面时间区间：00:28:38。
[13] 视频画面时间区间：00:29:48。

反向传播的数学原理

反向传播基于**链式法则（chain rule）**：

$$\frac{\partial L}{\partial w_i} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial w_i}$$

其中 L 为损失函数，a 为神经元激活值，w_i 为权重参数。通过将梯度从输出层逐层反向传播到所有参数，可以高效计算每个参数对损失的贡献，从而用梯度下降更新参数。

5.4 本章小结

数据（ImageNet）与算法（反向传播/CNN）的成熟汇聚，加上 GPU 算力的爆发，在 2012 年共同触发了 AlexNet 的历史性突破，开启了深度学习革命。数据是与架构同等重要的”一等公民”——这是 ImageNet 最重要的教训之一。

6 深度学习时代的爆发

6.1 2012 年之后的视觉任务爆炸

AlexNet 之后，计算机视觉迅速从图像分类拓展到更广泛的任务：

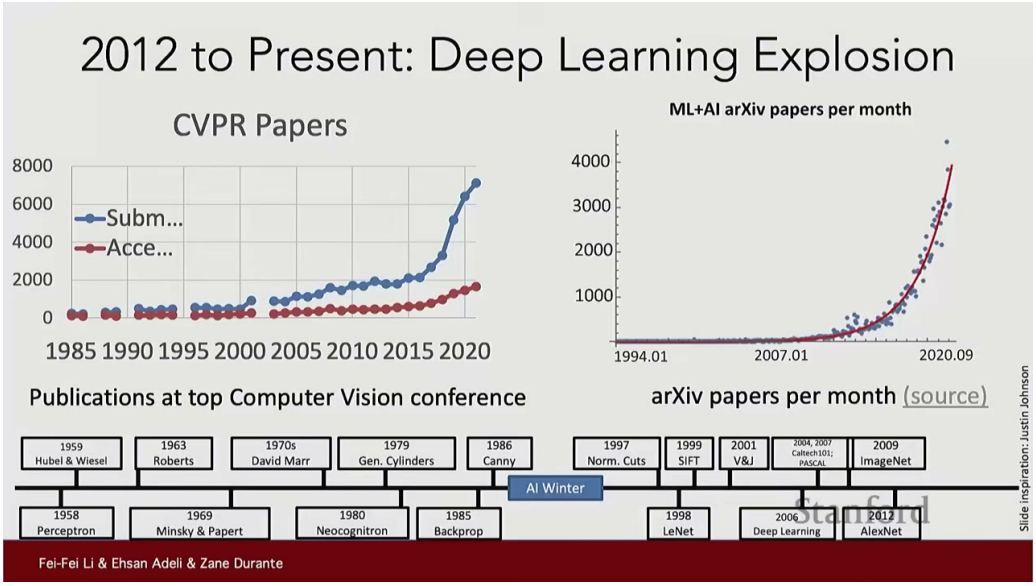

图 14: 2012 至今：CVPR 论文与 arXiv 论文数量的爆炸式增长[14]

主要任务类别：

- **图像分类**：给整张图像分配一个标签
- **目标检测**：定位并分类图像中的多个物体（边界框 + 类别标签）
- **图像分割**：语义分割（每像素分类）、实例分割（区分同类不同个体）
- **视频理解**：动作分类、人体行为识别

[14] 视频画面时间区间：00:36:04。

- **图像描述（Image Captioning）**：Andrej Karpathy 的博士论文工作
- **风格迁移（Style Transfer）**：Justin Johnson 的标志性工作
- **生成式 AI**：人脸生成、图像生成（早期 DALL-E）
- **医学影像**：病理切片、放射影像分析
- **科学发现**：黑洞照片的重建等

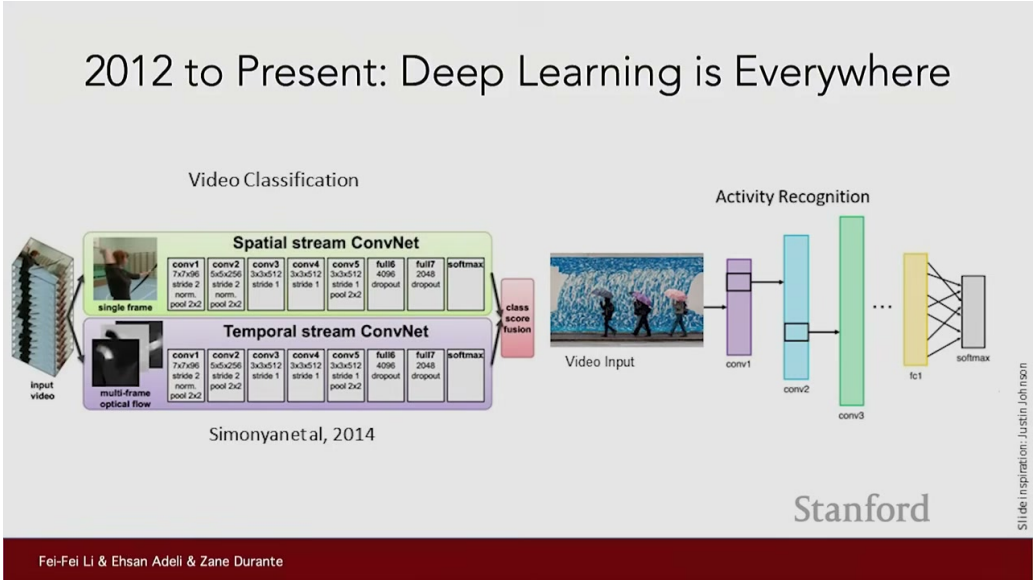

图 15: 深度学习无处不在：双流卷积网络实现视频分类与动作识别[15]

6.2 三大收敛力量

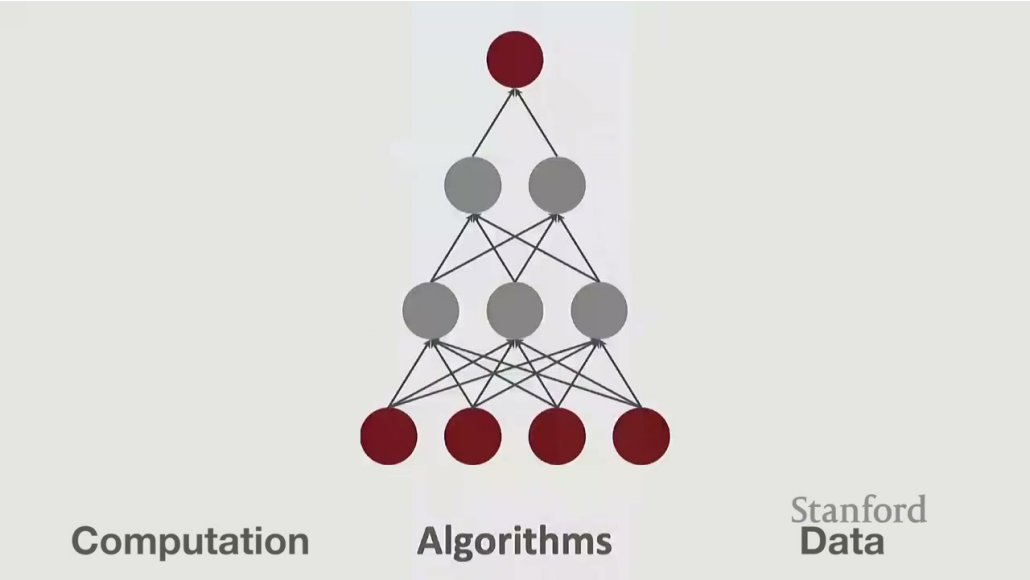

图 16: 三大收敛力量：计算（Computation）、算法（Algorithms）、数据（Data）[16]

[15] 视频画面时间区间：00:37:48。

三大收敛力量（Three Converging Forces）

现代 AI 爆发由三个要素的汇聚驱动：

1. **计算（Computation）**：GPU 算力指数增长，NVIDIA 等推动 FLOP/$ 持续跃升
2. **算法（Algorithms）**：反向传播、CNN、注意力机制、Transformer 等架构创新
3. **数据（Data）**：互联网、数码相机带来数据爆炸，ImageNet 等大规模数据集的构建

这三者的同时成熟，使整个领域彻底摆脱了 AI 寒冬，进入 AI 全球变暖时期（Fei-Fei Li 的比喻）。

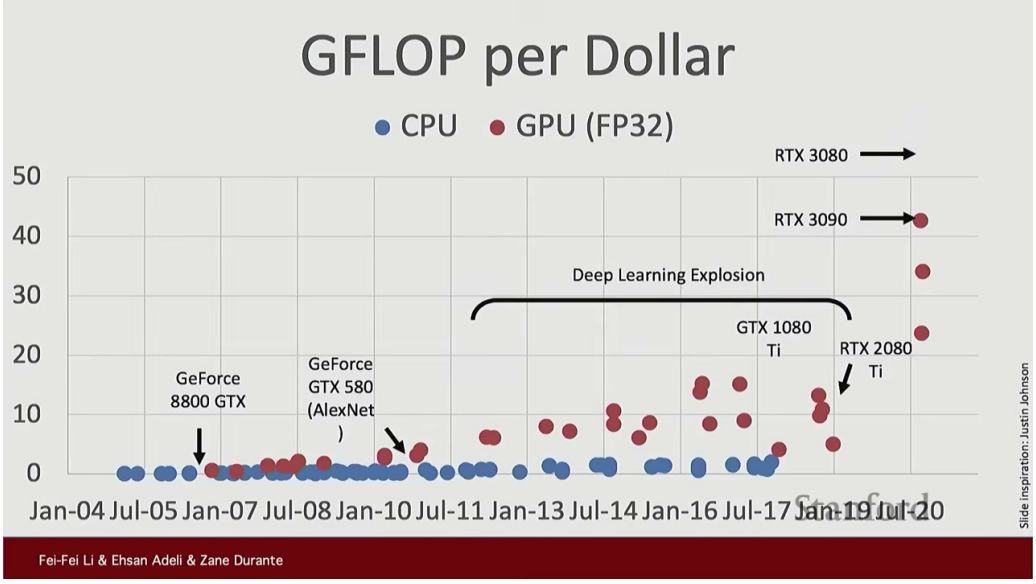

图 17: GPU 算力增长：GFLOP/$ 在深度学习时代呈指数加速[17]

NVIDIA GPU 的 FLOP/$ 在 2020 年之前稳步增长，深度学习兴起后则呈现**指数加速**。与此同时，各大 AI 学术会议参会人数、创业公司数量、企业 AI 应用数量全面爆发。

6.3 本章小结

2012 年后，计算机视觉迅速从图像分类扩展到全方位视觉任务。三大收敛力量（计算、算法、数据）共同推动整个领域进入加速增长轨道，AI 寒冬已成历史。

7 课程内容：四大主题模块

本节由 **Ehsan Adeli 教授**讲授，介绍课程的整体结构。

[16] 视频画面时间区间：00:40:09。

[17] 视频画面时间区间：00:40:51。

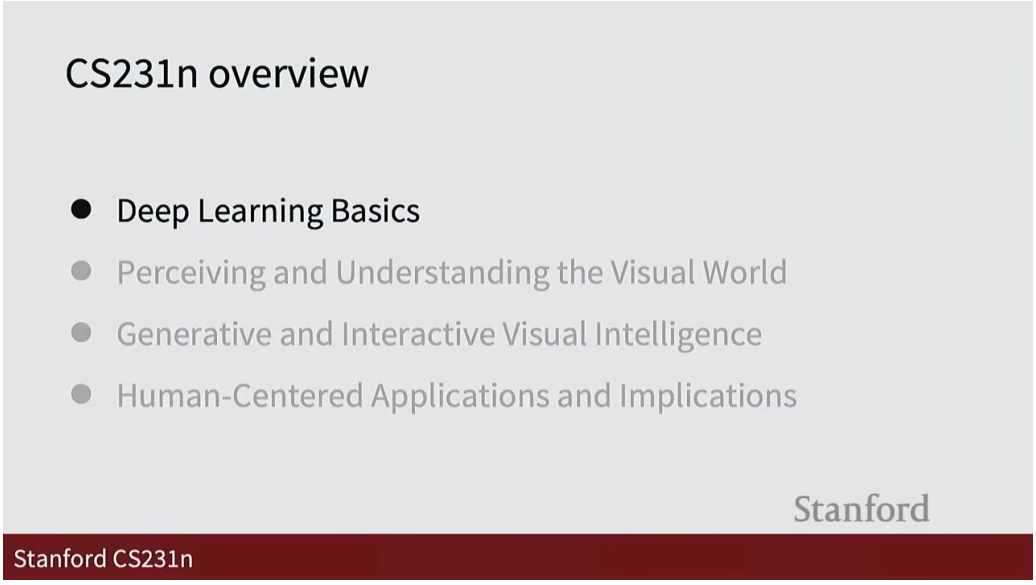

图 18: CS231n 课程四大模块概览[18]

7.1 模块一：深度学习基础

计算机视觉的核心任务是**图像分类**——给模型一张猫的图像，模型输出标签"cat"。这个看似简单的任务是更复杂应用（自动驾驶、医疗诊断等）的基础。

线性分类器：最简单的起点。将每张图像映射到特征空间中的一个点，线性分类器寻找分隔不同类别的**超平面**。

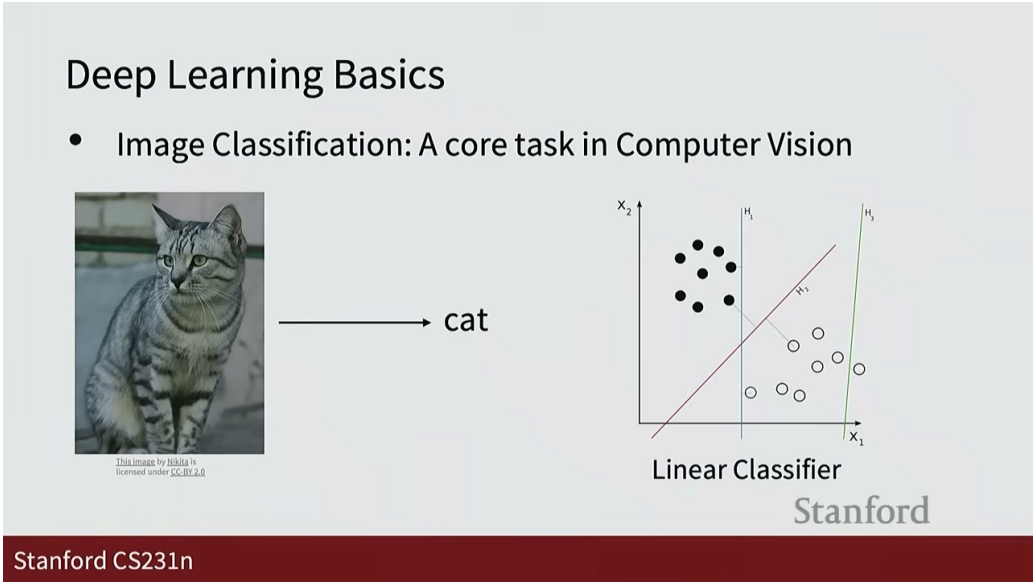

图 19: 深度学习基础：图像分类与线性分类器[19]

线性模型能力有限——当数据在特征空间中不线性可分时，会面临欠拟合。

[18] 视频画面时间区间：00:45:25。

[19] 视频画面时间区间：00:46:37。

过拟合与欠拟合：在合适的模型复杂度之间取得平衡，需要**正则化（regularization）**控制模型复杂度，**优化（optimization）**寻找最优参数。

神经网络：通过堆叠多层非线性操作来建模复杂函数，突破线性模型的局限。

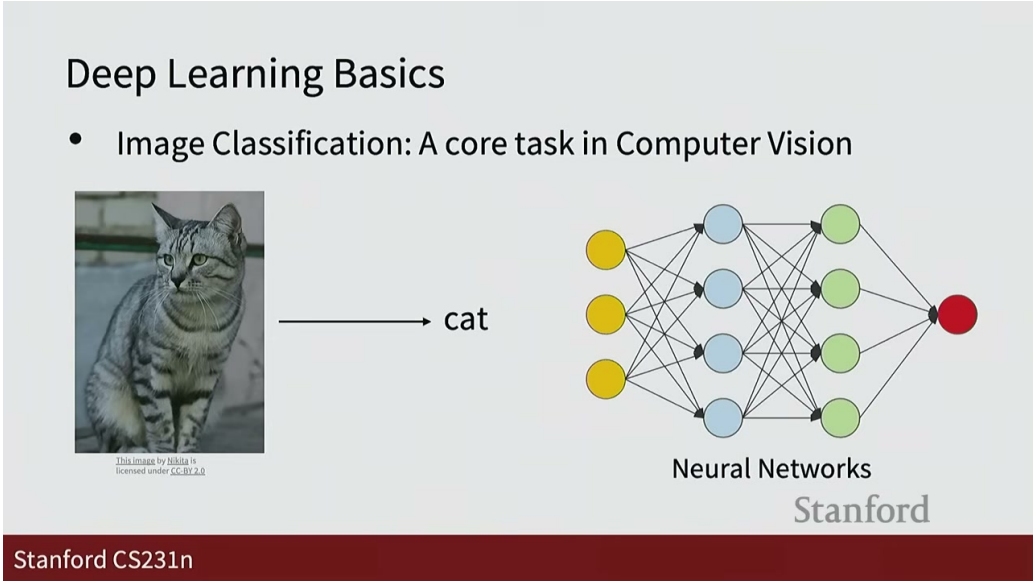

图 20: 神经网络：多层非线性变换实现复杂函数建模[20]

神经网络 vs 线性分类器

线性分类器只能学习线性决策边界。神经网络通过多层非线性激活函数的叠加，可以近似任意复杂函数（通用逼近定理），这是深度学习能力的理论基础。

7.2 模块二：感知与理解视觉世界

超越单标签分类，视觉理解包含丰富的任务体系：

- **语义分割（Semantic Segmentation）**：对图像中每个像素分配类别标签（草地、猫、树、天空），但不区分同类的不同实例
- **目标检测（Object Detection）**：不只是”什么”（类别），还要知道”在哪”（边界框）
- **实例分割（Instance Segmentation）**：最细粒度——结合检测与分割，每个物体实例拥有独立的掩码

时序维度：视频分类、多模态视频理解（视觉 + 音频）、可视化与注意力图（理解模型在关注什么）。

关键模型架构：

- **卷积神经网络（CNN）**：图像任务的主力架构，包含卷积、池化、全连接层
- **循环神经网络（RNN）**：处理序列数据（视频、文本）
- **Transformer & 注意力机制**：当前最强大的序列和视觉架构

[20] 视频画面时间区间：00:48:32。

7.3 模块三：大规模分布式训练

本学期新增内容。大语言模型和大型视觉模型的训练需要超大规模算力：

- **数据并行（Data Parallelism）**：将数据切分到多个设备上并行训练
- **模型并行（Model Parallelism）**：将模型本身切分到多个设备上
- 挑战：多设备间的同步、通信开销等

7.4 模块四：生成式与交互式视觉智能

自监督学习（Self-Supervised Learning）：模型从数据本身获取训练信号，无需人工标注。这是训练大规模视觉模型的关键技术，支撑了近年来计算机视觉的重大突破。

生成模型：

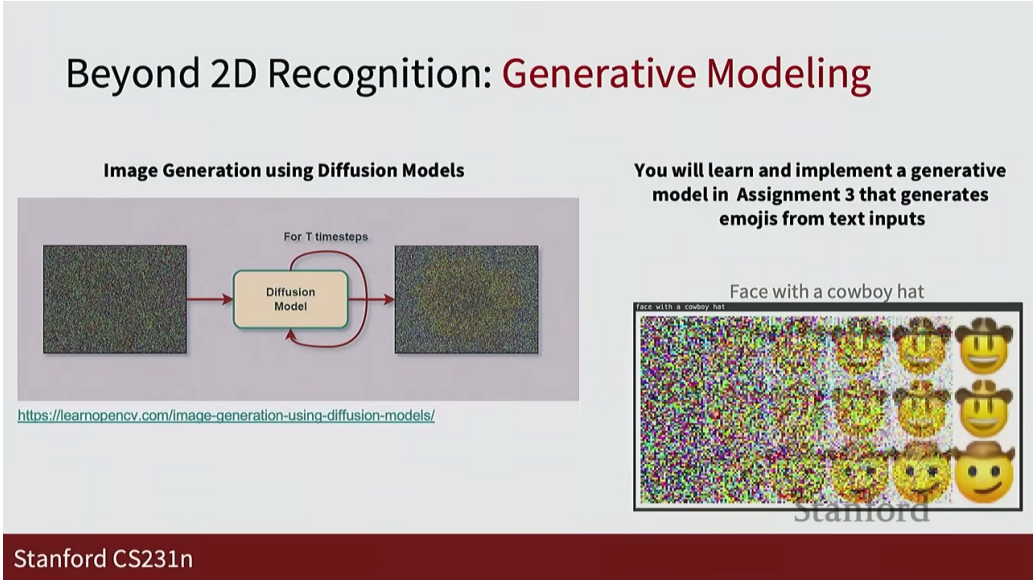

图 21: 生成模型：DALL-E 2 根据文字提示生成图像[21]

- **风格迁移**：将内容与风格分离，重组后生成新图像（Justin Johnson 的经典工作，将在课程中客座讲授）
- **DALL-E / 扩散模型**：给定文字提示生成图像；扩散模型通过学习逆向加噪过程来生成图像。Assignment 3 将实现从文字生成 emoji 的生成模型
- **视觉-语言模型（Vision-Language Models）**：将文本和图像在共享表示空间中对齐，支持跨模态检索、视觉问答等

[21] 视频画面时间区间：00:57:19。

图 22: 视觉-语言模型（VLM）：CLIP 对比预训练实现跨模态对齐[22]

超越 2D 的视觉：

- **3D 视觉**：从图像重建三维体素表示、形状补全、单视角 3D 目标检测；支撑机器人和 AR/VR 应用
- **具身智能（Embodied AI）**：在物理世界中感知、规划、执行的智能体，如机器人清扫房间、从人类示范中泛化

7.5 本章小结

课程四大模块覆盖了从基础到前沿的完整体系：深度学习基础 → 视觉感知与理解 → 大规模训练 → 生成式与交互式视觉智能。每个模块在前一个的基础上递进，最终指向当下最活跃的研究前沿。

8 人本 AI 与社会影响

8.1 AI 的”好”与”坏”

Fei-Fei Li 强调，强大的工具必然带来双重影响：

潜在危害：

- **人类偏见的放大**：所有大型 AI 系统都由数据驱动。数据是人类历史活动的产物，必然携带偏见。人脸识别算法已被证明存在类似人类的偏见
- **高风险决策的 AI 化**：招聘筛选、金融贷款等涉及人生的决策，若完全交由 AI 执行，是否合适？这不是纯工程问题，而是深刻的伦理与社会问题

[22] 视频画面时间区间：00:58:47。

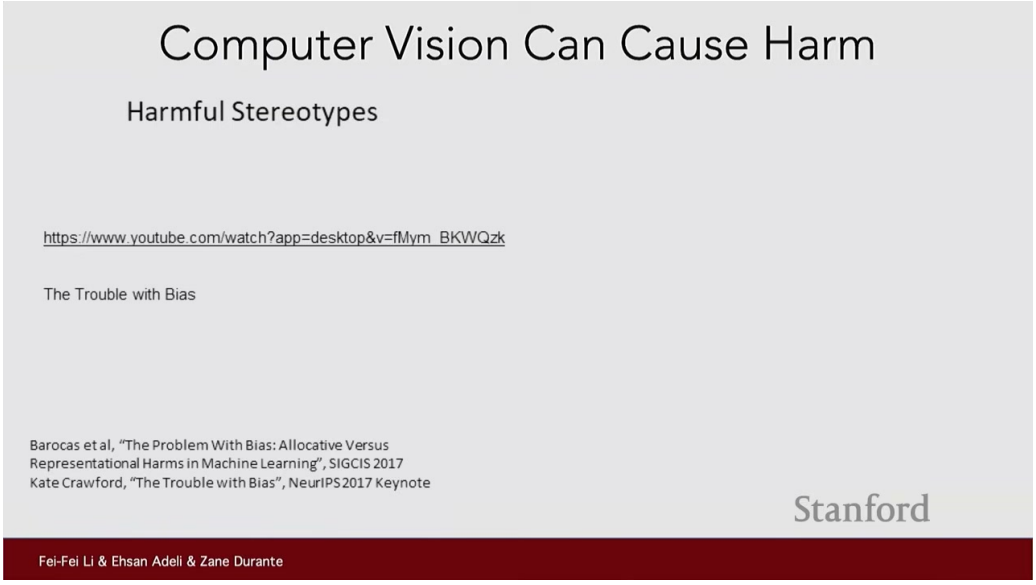

图 23: 计算机视觉可能造成的危害：有害刻板印象与偏见[23]

积极应用：

- **医疗影像**：放射科、病理科等视觉密集型医疗场景
- **AI for Aging & Health**：Fei-Fei Li、Adeli 和 Zane 的共同研究方向——使用计算机视觉为老年人和患者提供护理
- **科学发现**：黑洞照片重建等
- **可持续发展**：环境监测等

AI 的边界：人类视觉远未被复制

即便计算机视觉已取得惊人成就，人类视觉仍有 AI 无法企及的丰富维度：细微差别、隐含情感、幽默感、文化语境。孩子们学习时眼中的好奇，笑话图片中的机智——这些仍然超越当今所有 AI 系统。这不应让人沮丧，而应激励我们继续探索。

AI 问题不全是工程问题

Fei-Fei Li 特别指出：她非常欢迎来自医学院、法学院、教育学院、商学院的学生参加 CS231N。因为许多 AI 挑战本质上是人文、伦理和社会问题，而非纯技术问题。跨学科协作是负责任 AI 的必要条件。

8.2 领域里程碑：图灵奖与诺贝尔奖

- **2018 年图灵奖**（计算领域最高荣誉）：**Geoffrey Hinton**、**Yoshua Bengio**、**Yann LeCun** 因"使深度神经网络成为计算核心组件的概念和工程突破"获奖
- **2024 年诺贝尔物理学奖**：**Geoffrey Hinton** 和 **John Hopfield** 因"对神经网络的基础性贡献"获奖——这是 AI 研究首次获得诺贝尔奖

[23] 视频画面时间区间：00:42:21。

从 AI 寒冬到诺贝尔奖

Hinton 在 AI 寒冬期间数十年如一日研究神经网络，一度被主流认为是”旁门左道”。从寒冬到图灵奖再到诺贝尔奖，这段历史是坚持基础研究、抵抗短期主义的最佳注脚。

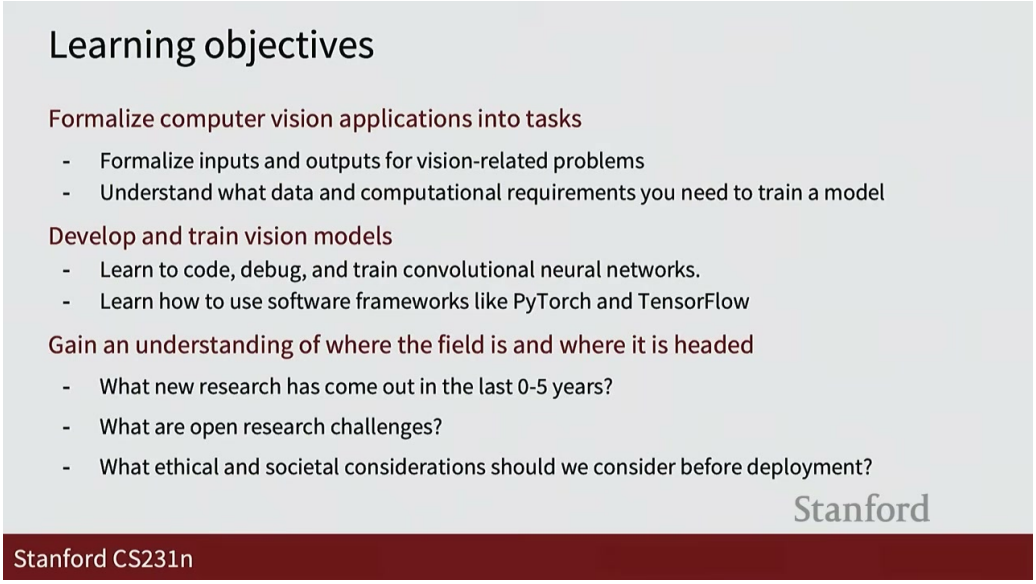

图 24: 课程学习目标：形式化视觉任务、训练模型、理解领域走向[24]

8.3 下一讲预告

下一讲（Lecture 2）将正式进入技术内容：

- **图像分类**的形式化定义
- **线性分类器**：从数学角度理解其工作原理
- 这是整个 CS231N 技术旅程的起点

8.4 本章小结

计算机视觉不只是技术问题，更是社会和伦理问题。人类偏见、高风险决策、数据隐私等挑战要求跨学科合作。与此同时，该领域的社会价值已被最高学术荣誉认可。

9 总结与延伸

9.1 讲师的结语与综合

Fei-Fei Li 的核心信息：

- 视觉是智能的基石，5.4 亿年的进化史就是最好的证明

[24] 视频画面时间区间：01:01:17。

- 尽管计算机视觉已能做很多，人类视觉的丰富性（细微差别、情感、幽默）仍是遥远的目标——这正是继续研究的动力
- AI 已成为真正的跨学科领域，她鼓励每位学生将所学带回自己的领域

Ehsan Adeli 的核心信息：

- 本学期四大模块从基础递进到前沿，打好基础才能理解深度（前几周需要耐心）
- 人本 AI 是贯穿课程的重要维度
- 课程学习目标：将视觉应用形式化为任务、开发并训练视觉模型、理解领域现状与走向

9.2 核心知识图谱

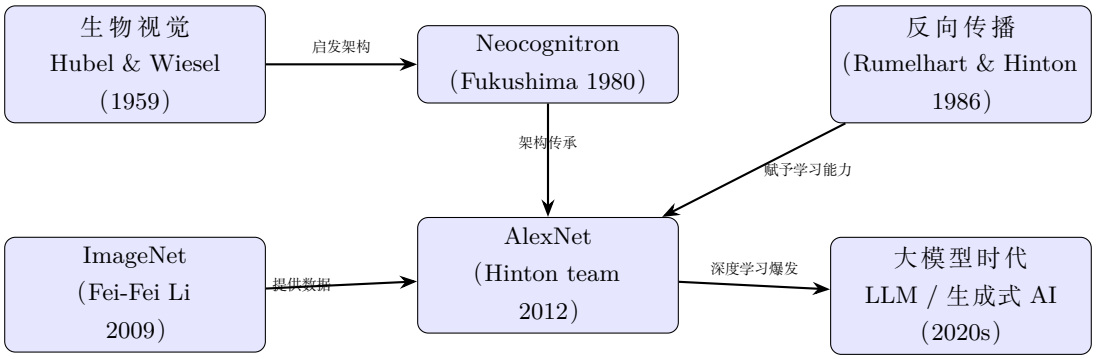

9.3 我的综合与延伸

主线逻辑：这堂课呈现了一条清晰的双线交织叙事——

1. **生物视觉线**：5.4 亿年进化 → Hubel & Wiesel（1959）→ 认知神经科学持续揭示视觉机制 → 启发计算架构
2. **算法数据线**：感知机 → Neocognitron（手工参数）→ 反向传播（自动学习）→ LeNet（小规模应用）→ ImageNet（数据革命）→ AlexNet（2012 爆发）

两条线在 2012 年 ImageNet 竞赛处交汇，共同点燃了深度学习革命。
核心洞见：

- **数据与算法同等重要**：在整个 AI 领域长期低估数据的背景下，ImageNet 的贡献不只是一个数据集，而是一种认识论上的纠偏
- **基础科学的长周期价值**：从 Hubel & Wiesel（1959）到诺贝尔奖（1981），从反向传播（1986）到图灵奖（2018）和诺贝尔物理学奖（2024），基础研究的回报需要数十年的耐心
- **视觉的哲学意义**：视觉不是生成的信号，而是对物理世界的被动测量——这与语言在本质上不同，决定了视觉问题和语言问题在算法上的根本差异
- **AI 全球变暖期**：Fei-Fei Li 用"AI 全球变暖" 而非"AI 春天" 来描述当下的加速期，暗示这种增长既有好处也有代价，不会轻易停止

开放问题：

- 现代大型视觉模型（如 GPT-4V、Gemini）是否真的”理解”图像，还是只是统计模式匹配？
- 人类视觉中的情感解读、常识推理、物理直觉，何时能被 AI 真正复制？
- 数据的偏见问题是否有根本性的技术解决方案，还是必须依赖社会和制度手段？

最重要的三个带走点

1. **数据是一等公民**：高容量模型（无论多少参数）必须有足够的、高质量的数据才能泛化
2. **三大收敛力量**：计算（GPU）+ 算法（反向传播/CNN/Transformer）+ 数据（ImageNet/互联网）——缺少任何一个，深度学习革命不会发生
3. **视觉 $\neq$ 已解决**：尽管成就惊人，当前最好的计算机视觉系统在细粒度理解、常识推理、情感感知等方面仍远不及人类

9.4 拓展阅读

- Hubel & Wiesel（1959）：*Receptive fields of single neurones in the cat's striate cortex*，Journal of Physiology
- Krizhevsky, Sutskever, Hinton（2012）：*ImageNet Classification with Deep Convolutional Neural Networks*（AlexNet 论文）
- Deng et al.（2009）：*ImageNet: A Large-Scale Hierarchical Image Database*
- David Marr（1982）：*Vision: A Computational Investigation into the Human Representation and Processing of Visual Information*（经典教材）